

CarePlus Predict V2

Relatório Executivo para CarePlus

Plataforma de telessaúde com três Inteligências Artificiais integradas:
RAG clínico, Prescrição com Human-in-the-Loop e Chat empático com contexto

GRUPO NEXTGEN

Gustavo Franzoti Gonçalves · RM 566983

Lincoln Simão Pereira · RM 567284

Maykon Santana Fonseca · RM 567041

Nicolas Sakaue Nishimura · RM 567752

Orientador: **Prof. Dr. Allan Roberto Molto**

FIAP — Trabalho de Conclusão de Curso
Junho de 2026

Sumário executivo

O **CarePlus Predict V2** é uma plataforma de telessaúde com inteligência artificial desenvolvida pelo Grupo NextGen como trabalho de conclusão de curso da FIAP. Integra três IAs distintas em operação: **RAG** para o médico, **Prescrição com Human-in-the-Loop** e **Chat clínico** com contexto rico para o paciente.

A solução é end-to-end: aplicativo móvel em React Native, dashboard web em React, backend Fastify em Node.js, serviço Python especializado em ML (chamado Blua), modelo de linguagem Llama 3.1 70B servido pelo Groq, e banco Supabase com extensão pgvector para busca semântica.

Diferente de soluções com IA generalista, o CarePlus Predict ancora cada resposta do médico em fontes verificáveis (RAG sobre protocolos clínicos curados), impede qualquer prescrição automática (HITL obrigatório por design), e protege o paciente com classificação de red flags clínicos e tom conservador no chat. Tudo construído sobre os princípios da LGPD desde o desenho — pseudonimização nativa, auditoria automática, consentimento granular.

Estado atual: as três IAs estão funcionais. **164 chunks vetoriais** indexados de 3 protocolos clínicos. **116 mensagens trocadas em 25 threads** no chat do paciente. **240 registros de auditoria**. **268 dias de dados reais** do Samsung Health do membro Maykon Fonseca, primeiro paciente real da plataforma. Próximo marco: piloto controlado com clínica parceira (50 a 200 pacientes).

1. Visão do produto

O CarePlus Predict resolve um problema concreto de telessaúde: a perda de continuidade entre consultas. Hoje, o paciente sai do consultório e fica em silêncio até a próxima visita. O médico, por outro lado, decide com base em memória, intuição e o pouco que enxerga em meia hora de conversa.

Nossa abordagem inverte essa lógica em três frentes: dados passivamente capturados de wearables abastecem o histórico do paciente em tempo real; protocolos clínicos curados pelo médico viram base de conhecimento consultável em linguagem natural; e um assistente conversacional 24/7 oferece orientação preliminar — sempre com salvaguardas de segurança clínica.

Princípio orientador: a IA atua como apoio à decisão clínica, jamais substituição. Toda funcionalidade que toca decisão regulada (prescrição, diagnóstico, encaminhamento) tem supervisão humana obrigatória. Toda informação que o paciente recebe vem com disclaimer claro de que não substitui consulta.

Identidade visual madura: três temas para três contextos

A identidade visual da plataforma foi pensada para três perfis de uso: **tema claro** para consultórios diurnos e clínicas institucionais; **tema escuro** para plantões noturnos e especialistas com longas horas de tela; e **tema futurista** — com glassmorphism, neon ciano e grade HUD — como diferencial de marca, posicionando o CarePlus como tecnologia de ponta em saúde.



Figura 1. Tela de login mobile no tema futurista — identidade visual moderna que comunica tecnologia avançada sem perder a clareza institucional.




Figura 2. Tela de configuração no tema futurista — o usuário escolhe a aparência com três chips ('Escuro', 'Claro', 'Futurista') e acessa as quatro seções essenciais: Meus Dados, Notificações, Privacidade & Consentimento (onde mora a integração Samsung Health), e Sobre. Layout limpo, hierarquia clara.

2. Detalhamento clínico

Esta seção é dedicada a leitores com formação clínica — direção médica, comitê de ética, sociedade médica parceira. Apresenta como cada decisão arquitetural responde a uma necessidade clínica concreta, com transparência sobre o que está amadurecido e o que ainda precisa de evolução.

Continuidade do cuidado entre consultas

O paciente abre o aplicativo e vê **seu score de saúde** calculado em tempo real (Figura 3) a partir de dados do wearable. O score consolida três métricas primárias — atividade física, frequência cardíaca de repouso, padrão de sono — em um número de 0 a 100 com classificação clara: estável, atenção, crítico. A linguagem evita jargão médico para não confundir o leigo.



Figura 3. Tela inicial do paciente — score 95 com label 'Estável', métricas-chave (FC média 78 bpm, 9.412 passos, 7,5h de sono, 95% de progresso), análise de risco categorizada e duas recomendações personalizadas no rodapé. Os dados são reais do Samsung Health, sincronizados via Bluetooth do Galaxy Watch.

A visão semanal consolida tendência (Figura 4). O paciente identifica padrões — queda no fim de semana, dia atípico, evolução positiva — sem precisar interpretar números crus. Esse engajamento contínuo é o que mais aumenta a aderência ao tratamento em condições crônicas (literatura mostra ganho de 15 a 30 por cento).



Figura 4. Métricas de saúde semanais — quatro KPIs no topo, gráfico de barras de atividade física, totais consolidados (36.912 passos no período, média de 7.382 por dia) e padrão de sono em gráfico de área. Visual limpo, fácil de ler em 5 segundos.

Prescrição com Human-in-the-Loop: o ponto regulatório mais sensível

Prescrição é decisão clínica regulada pelo Conselho Federal de Medicina. A Resolução CFM 2.314/2022 exige supervisão humana em qualquer decisão clínica apoiada por IA. Nosso desenho atende essa exigência **por arquitetura** — não há caminho técnico para uma prescrição virar ação real sem aprovação explícita de médico humano.




Figura 5. Fila de prescrições aguardando revisão médica (HITL). Três sugestões geradas pela IA com pacientes pseudonimizados (PT-9F2A-31, PT-7C04-88, PT-1B5E-12) — o revisor vê apenas o código, nunca o nome, mitigando viés. Cada item mostra a sugestão completa (medicamento, dose, frequência, duração, justificativa) e dois botões: Aprovar ou Rejeitar.

A **pseudonimização** mostrada na Figura 5 tem propósito clínico explícito: evitar que o médico revisor seja influenciado pelo conhecimento prévio do paciente. Em uma carteira de 1.000 pessoas, o profissional pode ter um viés (favorável ou contrário) ao ver o nome — o código PT-9F2A-31 neutraliza isso. Atende ao princípio LGPD da minimização de dados.

Transparência técnica: o gatilho automático que cria sugestões de prescrição a partir do chat do paciente ainda está em maturação. Hoje há uma sugestão de teste no banco de produção. Em uso real, esse trigger demandará critérios clínicos rigorosos e validação por médicos parceiros. As red flags do chat são detectadas hoje por correspondência de palavras-chave (dor_torax, falta_ar_aguda) — funciona para os casos mais óbvios, com espaço para evoluir para um classificador supervisionado.

3. Detalhamento técnico

Esta seção é destinada a leitores com formação técnica — diretoria de tecnologia, arquitetos, time de engenharia que avaliará integração ou aquisição. A arquitetura foi desenhada para três objetivos simultâneos: **baixo custo operacional** (viabilizar modelos de negócio acessíveis), **portabilidade de LLM** (não depender de uma única empresa) e **compliance regulatória** (LGPD e CFM atendidos por design).

Stack e arquitetura

Três serviços trabalham em conjunto: o **Backend Fastify** em Node.js orquestra autenticação JWT, regras de negócio e persistência. O **serviço Blua** em Python centraliza machine learning — gera embeddings via Sentence-Transformer (modelo multilingual-e5-small, 384 dimensões, multilíngue PT/EN) e compõe os prompts para o LLM. O **Groq**, provedor externo, executa o modelo **Llama 3.1 70B** (Meta, open weights) com latência típica de 50ms e throughput de 250 tokens por segundo.

O **Supabase** (Postgres 15 com extensão pgvector) armazena dados clínicos, conversas, e os vetores de busca semântica — tudo no mesmo schema, com transações ACID consistentes entre dados clínicos e índices vetoriais. Hospedagem em AWS us-east-1.

Decisão arquitetural relevante: o backend Fastify *nunca* chama o Groq diretamente. Toda chamada a LLM passa pelo Blua. Isso isola a lógica de IA do orquestrador. Se amanhã uma regulação exigir LLM rodando em infra brasileira, ou se quisermos trocar Groq por Together ou Anthropic, a mudança fica em um único serviço — o resto do sistema não é afetado.

As três IAs em detalhe

RAG (Retrieval-Augmented Generation) para o médico: protocolos clínicos em PDF são divididos em chunks de 500 a 800 caracteres, vetorizados pelo Blua e persistidos em rag_chunks. Quando o médico pergunta, a pergunta é embedada com o mesmo modelo, e a função SQL match_rag_chunks usa o operador <=> do pgvector para retornar os trechos mais similares por cosseno. O Blua monta o prompt 'Use estes trechos: Fonte 1, Fonte 2... Pergunta:...' e chama o Groq. A resposta vem com referências verificáveis — diferente de LLMs que alucinam fontes.

Curadoria — medico envia protocolo clinico



Query — medico faz pergunta clinica




Figura 6. Fluxo RAG — curadoria (médico envia PDF, backend chunka, Blua embedda, pgvector armazena) e query (pergunta → embedding → busca top-K → Groq com fontes → resposta com referências). Validado em produção com 164 chunks indexados.





Figura 7. Tela da IA do Médico no dashboard web. Lateral direita mostra os três documentos curados pela equipe — Diretriz HAS 2024 SBC (142 trechos), Protocolo Diabetes Tipo 2 (88 trechos), Manual de triagem cardiovascular (61 trechos). Total: 291 trechos vetorizados para consulta.

Prescrição com HITL: sugestões da IA entram em prescriptions com status pendente, paciente identificado por código BNF pseudonimizado. Médico revisa via POST /ai/prescriptions/:id/review. Toda decisão grava em auditoria — trilha exigida pelo CFM.

Geracao — IA propoe (status: pendente)



Revisao — medico decide



Pseudonimizacao: revisor ve apenas paciente_bnf (ex: PT-9F2A-31)

Toda decisao grava em auditoria (acao=prescription.review)

Figura 8. Fluxo HITL — IA propõe (status pendente) → médico revisa pseudonimizado → decisão registrada com trilha de auditoria. Pseudonimização e auditoria são nativas do banco, não opcionais.

Chat clínico para o paciente: o backend monta o prompt em três camadas — sistema (instruções restritivas), contexto (anamnese + últimas 7 leituras de wearable + nome) e histórico (últimas mensagens da thread). Após resposta do Groq, classifica intent (duvida_geral, queixa_sintoma, pedido_prescricao) e detecta red flags. Mensagem e resposta vão para ai_messages.




Figura 9. Fluxo do chat paciente — contexto coletado em três camadas, prompt enviado ao Groq, resposta classificada quanto a intent e red flags, persistida em ai_messages. Red flags podem disparar fluxos colaterais como notificação ao médico de plantão.




Figura 10. Dashboard de métricas agregadas — score médio da carteira do médico calculado em tempo real, distribuição de risco (60% baixo, 25% médio, 15% alto), gráfico de passos médios dos últimos 30 dias. Tudo computado no Postgres, sem ETL ou data warehouse separado.

Custo operacional

Llama 3.1 70B via Groq custa US\$ 0,59 por milhão de tokens de entrada e US\$ 0,79 por milhão de tokens de saída — uma ordem de grandeza menor que GPT-4 (US\$ 30 por milhão). Para uma clínica com 1.000 pacientes ativos e cinco mensagens diárias por paciente em média, o custo Groq fica em torno de US\$ 30 por mês. Os embeddings rodam localmente no Blua — sem custo por chamada, apenas a infra fixa do serviço Python.

4. Detalhamento comercial

Esta seção é direcionada a leitores comerciais — direção de novos negócios, estratégia, fusões e aquisições. Apresenta o produto mínimo viável (que já existe em produção), os três segmentos-alvo em ordem de facilidade de venda, e o diferencial competitivo na paisagem de healthtech brasileiro.

Produto mínimo viável em produção

Para o médico, o dashboard web já entrega visão executiva da carteira em 5 segundos: total de pacientes, em acompanhamento, métricas-chave agregadas, lista de pacientes recentes com badge de risco. É a tela que converte em reuniões de venda — abre a conversa.




Figura 11. Dashboard inicial do médico — 'Olá, Helena'. Cinco pacientes ativos, três em acompanhamento intensivo, média de 7.082 passos, 36 consultas no mês. Lista mostra Marina Alves (risco médio), João Bertoldo (saudável), Cláudia Ferraz (alto risco), Rafael Nunes (saudável), Tereza Lima (risco médio). Cada paciente com idade, métricas e badge categórico.




Figura 12. Visão por paciente — Marina Alves, 54 anos, risco médio. Note o selo verde 'REAL - Apple Watch' ao lado do nome: indica que esse paciente tem integração ativa com wearable, dados reais sincronizando. Diferenciação visual imediata entre pacientes em demonstração e em uso real — fundamental para credibilidade em reuniões. Gráfico de evolução de passos nos últimos 30 dias visível para o médico.

Três segmentos de venda

Segmento 1 — Clínicas de medicina preventiva e check-up (alvo primário). Decisão rápida (decisor único costuma ser o sócio-fundador médico), pacientes engajados que já usam wearables, ticket razoável de R\$ 200 a R\$ 600 por paciente por ano, risco regulatório controlado porque o paciente vai presencialmente em momentos-chave. Exemplos: redes como Dasa Preventive, Einstein Connect, ou clínicas independentes de longevidade. Tipicamente 500 a 5.000 pacientes ativos.

Segmento 2 — Operadoras de saúde com programas de doenças crônicas. Hipertensão, diabetes e DPOC representam 40 a 60 por cento do custo assistencial das operadoras. Gestão remota desses pacientes tem ROI mensurável (redução de internações). Ciclo de venda mais longo, 6 a 12 meses, mas contratos volumosos. Exemplos: Hapvida, Bradesco Saúde, Unimed, Amil — cada uma com 500 mil a 10 milhões de vidas.

Segmento 3 — Profissionais autônomos. Cardiologistas, endocrinologistas, geriatras. Ticket baixo por médico, escala via marketplace ou white-label. Venda direta B2C2B — o médico paga, o paciente usa.

Diferencial competitivo: a combinação de RAG, HITL e Chat empático integrada em uma única plataforma é rara no mercado brasileiro. Empresas de healthtech tipicamente entregam uma dessas peças isoladamente. Entregar as três conectadas, com identidade visual consistente e compliance LGPD/CFM nativos, é nossa marca registrada.

5. Detalhamento de marketing

Esta seção é destinada a leitores de marketing e marca — equipe de comunicação, branding, campanhas. Apresenta a identidade visual diferenciada por persona, o tom de voz adotado em todo o produto, o posicionamento competitivo e casos de uso para storytelling em campanhas.

Tom de voz

O produto inteiro fala em uma voz só: **técnica mas acessível, transparente sobre limitações da IA, conservadora clinicamente**. Três mensagens-chave atravessam toda a comunicação:

"IA como apoio à decisão clínica, jamais substituição."

"Toda prescrição passa por médico humano."

"Suas respostas vêm com a fonte exata do protocolo clínico."

Posicionamento de marca

Telessaúde com IA fundamentada em evidência — não alucinação. Esse é o pilar central. O mercado está saturado de promessas vazias sobre IA em saúde. Diferenciamos pela ancoragem em fontes (RAG), pela responsabilidade humana explícita (HITL) e pela transparência sobre o que ainda não está pronto. É um posicionamento adulto, dirigido a decisores adultos.

Casos de uso para storytelling

Caso 1 — Continuidade do cuidado: Maykon Fonseca, membro do nosso grupo, usa o aplicativo no Galaxy Watch dele há 268 dias. Dados de FC, passos e sono sincronizados sem fricção. É o primeiro paciente real da plataforma — o caso concreto que prova que o produto funciona em condições normais.

Caso 2 — Médica decidindo com confiança: Dra. Helena recebe na fila uma sugestão de Losartana 50mg para um paciente identificado apenas como PT-9F2A-31. Em 30 segundos abre o histórico do paciente (passos, FC, sono dos últimos 30 dias) e a justificativa da IA citando o protocolo HAS 2024. Aprova com confiança porque a recomendação está fundamentada em evidência.

Caso 3 — Paciente atendido às 22h: Maria, 32 anos, hipertensa controlada, conversa com o chat sobre uma dor de cabeça leve. O sistema detecta ausência de red flags, orienta hidratação e descanso, e sugere consulta presencial se persistir 48 horas. Dra. Helena valida a conversa pela manhã. Nenhum atendimento de emergência desnecessário, nenhum paciente em sofrimento sem orientação.

6. Roadmap e proximos marcos

Proximos 30 dias - Piloto controlado

Operacionalizacao com uma clinica parceira: 50 a 200 pacientes voluntarios, 5 a 15 medicos. Foco em refinamento do gatilho automatico de prescricao com casos clinicos reais, validacao das red flags por keyword versus casos verdadeiros, e ajuste do tom da IA conforme feedback dos usuarios. Criterio de saida: 30 dias sem incidentes graves, NPS acima de 50, medico pagante.

Proximos 90 dias - Escala regional

Expansao para 2 a 3 clinicas. Sem mudanca arquitetural relevante - mesmo Supabase, mesmo Railway. Investimentos necessarios: contratar 1 Customer Success, 1 desenvolvedor frontend para painel administrativo, 1 medico-consultor para curadoria assistida da base RAG.

6 meses - Primeira operadora piloto

Negociacao de piloto com uma operadora de saude em programa de doencas cronicas. Multi-tenancy real (cada cliente em seu proprio schema), painel de gestao para administradores, metricas de uso por cliente. Inicio do processo de SOC 2 Type 2 para credenciar a plataforma em vendas enterprise.

7. Estado atual - transparencia tecnica

Esta secao e nossa autoavaliacao honesta sobre o que esta pronto e o que ainda demanda evolucao. Documento tecnico serio precisa dessa transparencia - especialmente para uma empresa do porte da CarePlus/Bupa.

RAG (IA do Medico) - 100 por cento funcional

Validado em producao via consulta direta ao endpoint. Pergunta 'o que e hipertensao?' retorna resposta coerente com 5 fontes citadas dos protocolos carregados. Curadoria de novos PDFs tambem funciona - o medico pode adicionar documentos pelo dashboard a qualquer momento, indexacao acontece em segundos.

Prescricao (HITL) - backend e UI prontos, gatilho automatico em maturacao

A tabela prescriptions existe, API de listagem e revisao funciona, dashboard mostra a fila corretamente. Hoje ha 1 registro no banco (de teste). O componente que ainda nao foi exercitado em producao real e o gatilho automatico que cria uma prescricao pendente quando a IA do chat detecta intencao pedido_prescricao. Em uso real, esse trigger precisara de criterios rigorosos validados por medicos parceiros.

Chat paciente - end-to-end funcional

Endpoint /ai/chat operacional, com 116 mensagens trocadas em 25 threads distintas no banco. Classificacao de intent e red flags por keyword matching - funciona para casos obvios, com espaco para evolucao. Em uma versao futura, esse classificador poderia ser um modelo supervisionado dedicado ou um sub-prompt estruturado ao proprio Groq.

Proximos passos arquiteturais

Tres direcoes valem investimento prioritario: substituir o keyword-matching de red flags por classificador supervisionado; maturar o gatilho automatico de prescricao com regras clinicas explicitas e metricas de falso-positivo; expandir o RAG com mais protocolos clinicos curados pelos medicos parceiros.

Apêndice - Schema das tabelas relevantes

Referência completa do banco de dados. Chaves estrangeiras explicitadas com seta. Tipos resumidos para legibilidade.

rag_documents

```
id (uuid PK), owner_id, titulo, nome_arquivo, tipo='pdf', status='processando',  
num_chunks, erro, criado_em
```

rag_chunks

```
id (uuid PK), document_id, owner_id, ordem, conteudo, embedding vector(384),  
criado_em
```

prescriptions

```
id (uuid PK), paciente_user_id, paciente_bnf, thread_id, sugestao jsonb,  
status='pendente', revisado_por_medico, revisado_em, observacao_medico,  
criado_em
```

ai_threads

```
id (uuid PK), user_id, bnf_code, perfil, criado_em, atualizado_em
```

ai_messages

```
id (uuid PK), thread_id, autor ('user'|'ia'), texto, intent, red_flags jsonb,  
criado_em
```

anamnese

```
id (uuid PK), user_id (UNIQUE), versao_questionario='v1', respostas jsonb,  
completa, criado_em, atualizado_em
```

health_readings

```
id (uuid PK), user_id, data_ref, passos, sono_horas, fc_media, fc_min, fc_max,  
origem='samsung_health', is_simulated=false, criado_em
```

patient_pseudonyms

```
user_id (PK), bnf_code (UNIQUE), criado_em
```

auditoria

```
id (uuid PK), ator_id, acao, entidade, entidade_id, detalhe jsonb, criado_em
```

Documento elaborado pelo Grupo NextGen - FIAP, Junho de 2026. Orientador: Prof. Dr. Allan Roberto Molto. Versão 1.0 em pt-BR.