FIAP — Faculdade de Informática e Administração Paulista
Turma 1CCPS | Projeto Next Gen

Care Plus
PREDICT

Documentação Técnica Completa

Plataforma de Predição e Integração da Saúde com Inteligência Artificial Adaptativa

Equipe de Desenvolvimento — Next Gen
Gustavo Franzotti Gonçalves — RM: 566983
Lincoln Simão Pereira — RM: 567284
Maykon Santana Fonseca — RM: 567041
Nicolas Sakaue Nishimura — RM: 567752

Scrum Master: Allan Roberto | São Paulo, 2025

Sumário

Sumário 2
1. Introdução e Visão Geral do Projeto 4
1.1 Contexto e Problema 4
1.2 Solução Proposta 4
2. Arquitetura Atual do Sistema 5
2.1 Status Atual de Desenvolvimento 5
2.2 Próxima Fase de Desenvolvimento 5
3. Proposta de Melhoria: IA Adaptativa com Aprendizado Contínuo 6
3.1 Conceito: IA no Modelo NotebookLM Aplicada à Saúde 6
3.2 Arquitetura do Sistema de IA Adaptativa 6
3.2.1 Camada de Coleta de Dados (Data Ingestion Layer) 6
3.2.2 Camada de Processamento e Feature Engineering 7
3.2.3 Camada de Modelos Preditivos 7
3.2.4 Mecanismo de Aprendizado Contínuo (Continual Learning) 8
3.2.5 Camada de Predição e Alertas 8
4. Melhoria da Coleta de Informações via API 9
4.1 Arquitetura de Integração Expandida 9
4.1.1 Samsung Health Data SDK — Implementação Avançada 9
4.1.2 Novas APIs a Integrar 9
4.1.3 Padrão FHIR para Interoperabilidade 10
4.2 Camada de API Gateway 10
4.3 Pipeline de Dados em Tempo Real 10
5. Segurança, Privacidade e Conformidade 11
5.1 Princípios de Segurança 11
5.2 Conformidade Regulatória 11
5.3 Logs de Auditoria e Rastreabilidade 12
6. Proposta de Valor e Diferenciais Competitivos 13
6.1 Para Pacientes 13
6.2 Para Profissionais de Saúde 13
6.3 Diferenciais Competitivos 13
7. Metas de Sucesso e Métricas 15
7.1 Métricas Técnicas 15
7.2 Impacto Esperado 15
7.3 Roadmap de Desenvolvimento 15

8. Stack Tecnológica Proposta (Atualizada) 17
8.1 Front-End e Mobile 17
8.2 Back-End 17
8.3 Banco de Dados 17
8.4 Machine Learning e IA 17
9. Fluxo do Sistema de IA Adaptativa — Passo a Passo 19
10. Conclusão 20

1. Introdução e Visão Geral do Projeto

O CarePlus Predict é uma plataforma integrada de saúde desenvolvida com o objetivo de unificar, prever e monitorar o estado de saúde de pacientes por meio de mecanismos científicos e Inteligência Artificial adaptativa. O projeto nasce como iniciativa acadêmica da FIAP em parceria com a Care Plus (Part of Bupa), e propõe uma abordagem moderna e centrada no usuário para resolver lacunas críticas no ecossistema de saúde digital brasileiro.

1.1 Contexto e Problema

O sistema de saúde atual enfrenta três grandes desafios estruturais que comprometem a qualidade do atendimento e a experiência do paciente:

- Fragmentação nos dados de saúde: informações distribuídas em múltiplos sistemas sem integração, dificultando uma visão holística do paciente.
- Ausência de ferramentas preditivas acessíveis: a prevenção é relegada ao segundo plano por falta de tecnologia escalável e de baixo custo.
- Monitoramento descontinuado: o acompanhamento da saúde ocorre apenas em consultas pontuais, sem continuidade entre os atendimentos.

1.2 Solução Proposta

O CarePlus Predict propõe três pilares de solução:

- Plataforma unificada de dados: centralização das informações de saúde do paciente em um único repositório seguro e acessível.
- Algoritmos preditivos para prevenção: uso de modelos de Machine Learning treinados continuamente com dados reais do usuário para antecipar riscos de saúde.
- Monitoramento contínuo integrado: coleta permanente de dados biométricos via wearables e APIs de saúde, eliminando gaps entre consultas.

2. Arquitetura Atual do Sistema

A arquitetura do CarePlus Predict foi projetada com foco em escalabilidade, interoperabilidade e privacidade nativa. Abaixo está o detalhamento de cada camada do sistema conforme definido na fase atual de desenvolvimento.

Plataformas	Back-End / Database	APIs Relacionadas	Interface de Usuário	Ferramentas do Sistema
SO Android	PostgreSQL	Samsung Health Data SDK	React Native (Android)	Sistemas de Prontuário
WEB	Node.js		React Native (WEB)	Wearable Samsung
	Python			

2.1 Status Atual de Desenvolvimento

As seguintes entregas foram concluídas na fase inicial do projeto:

- Aplicativo móvel funcional: versão operacional do app para Android com fluxos principais implementados.
- Interface de usuário: design system completo com componentes reutilizáveis em React Native.
- Simulações de dados: conjunto de dados sintéticos para validação dos fluxos de negócio.
- Arquitetura técnica: definição completa das camadas de sistema, protocolos de comunicação e modelo de dados.

2.2 Próxima Fase de Desenvolvimento

A segunda fase do projeto priorizará:

- Integração com APIs reais de saúde (Samsung Health, prontuários eletrônicos, laboratórios parceiros).
- Modelos preditivos avançados treinados com dados clínicos reais.
- Validação com dados reais de pacientes em ambiente controlado e com consentimento explícito.

3. Proposta de Melhoria: IA Adaptativa com Aprendizado Contínuo

Esta seção descreve em detalhes a principal melhoria técnica proposta para o CarePlus Predict: a implementação de um sistema de Inteligência Artificial adaptativa que aprende continuamente com base nos dados coletados pelo wearable e outras fontes integradas do usuário.

3.1 Conceito: IA no Modelo NotebookLM Aplicada à Saúde

Assim como o Google NotebookLM constrói um modelo de linguagem personalizado a partir dos documentos fornecidos pelo usuário, o CarePlus Predict propõe um sistema de IA que cria e continuamente refina um modelo de saúde personalizado para cada paciente, alimentado pelos dados coletados em tempo real.

Analogia com NotebookLM: Como Funciona o Aprendizado Adaptativo

NotebookLM (Referência)	CarePlus Predict IA Adaptativa
Documentos do usuário como base de conhecimento	Dados biométricos e histórico clínico do paciente
Responde perguntas com base nos documentos	Prediz riscos com base no perfil individual
Aprende com novos documentos adicionados	Aprende com novos dados do wearable e consultas
Modelo isolado por usuário	Modelo de saúde isolado e privado por paciente
Respostas contextualizadas ao conteúdo	Alertas contextualizados ao histórico de saúde

A diferença fundamental está no domínio: enquanto o NotebookLM processa texto, o CarePlus Predict processa séries temporais biomédicas — frequência cardíaca, saturação de oxigênio, padrões de sono, variabilidade de humor, atividade física — e cruza esses dados com o histórico clínico do paciente para gerar predições individualizadas e clinicamente relevantes.

3.2 Arquitetura do Sistema de IA Adaptativa

3.2.1 Camada de Coleta de Dados (Data Ingestion Layer)

A coleta de dados ocorre de forma contínua e multimodal:

- Wearable Samsung: frequência cardíaca (HR), variabilidade da frequência cardíaca (HRV), SpO2, temperatura corporal de superfície, passos, calorias, qualidade e estágios do sono (REM, NREM, deep sleep).
- App Mobile: autorregistros de humor, dor, sintomas, alimentação e uso de medicamentos.
- APIs de Prontuário Eletrônico: histórico de exames laboratoriais, diagnósticos, prescrições e internações.
- APIs de Laboratório: resultados de exames integrados automaticamente ao perfil do paciente.
- Dados Contextuais: localização (para correlação com qualidade do ar e alergias sazonais), padrões climáticos.

3.2.2 Camada de Processamento e Feature Engineering

Os dados brutos coletados precisam ser transformados em features significativas para o modelo de ML. Esse processo inclui:

- Normalização e limpeza: tratamento de valores ausentes, outliers de sensor e erros de sincronização.
- Geração de features temporais: médias móveis, tendências de curto e longo prazo, desvios padrão em janelas temporais (1h, 6h, 24h, 7d, 30d).
- Detecção de padrões: identificação de ritmos circadianos, variações semanais e sazonais.
- Correlação cruzada: relação entre qualidade do sono e frequência cardíaca em repouso; correlação entre nível de estresse (HRV) e padrões alimentares.
- Encodings de histórico clínico: representação vetorial de diagnósticos e medicamentos via técnicas de NLP médico (ex: SNOMED CT embeddings).

3.2.3 Camada de Modelos Preditivos (A ANALISAR)

O sistema de IA do CarePlus Predict é composto por múltiplos modelos especializados, cada um responsável por uma dimensão específica da saúde:

Modelo	Tipo	Input Principal	Output	Precisão-Alvo
Risco Cardiovascular	Gradient Boosting (XGBoost)	HR, HRV, SpO2, histórico	Score de risco 0-100	> 92%
Predição de Anomalias	LSTM Autoencoder	Séries temporais contínuas	Alerta de desvio	> 95%
Padrão de Sono	Random Forest + CNN	Acelerômetro, HR noturno	Classificação de qualidade	> 90%
Risco de Recaída	Transformer (HealthFormer)	Histórico clínico + wearable	Janela de risco	> 88%
Estresse e Saúde Mental	SVM + HRV features	HRV, padrões de movimento	Índice de estresse	> 85%

3.2.4 Mecanismo de Aprendizado Contínuo (Continual Learning)

O diferencial central do sistema é sua capacidade de aprender individualmente com cada usuário ao longo do tempo, sem esquecer o conhecimento prévio — um conceito conhecido como Continual Learning ou Lifelong Learning em ML:

- Modelo Base Global: treinado offline com grandes datasets clínicos anonimizados (PhysioNet, MIMIC-III, dados parceiros CarePlus). Fornece o ponto de partida para todos os usuários.
- Fine-Tuning Personalizado: ao longo das primeiras semanas de uso, o modelo base é refinado com os dados específicos do usuário usando técnicas de transfer learning, criando um modelo individual.
- Atualização Incremental: novos dados coletados pelo wearable são processados periodicamente (ciclos de 24 horas) para atualizar o modelo pessoal sem retreinar do zero.
- Elastic Weight Consolidation (EWC): técnica aplicada para evitar que o aprendizado de novos padrões apague conhecimento anterior importante — análogo à prevenção de 'catastrofic forgetting'.
- Federated Learning: os modelos são atualizados localmente no dispositivo do usuário, e apenas gradientes (nunca dados brutos) são compartilhados com o servidor central, preservando a privacidade.

3.2.5 Camada de Predição e Alertas

As predições geradas pelos modelos são transformadas em alertas e insights acionáveis:

- Alertas Preventivos em Tempo Real: notificações push quando o modelo detecta padrões que precedem historicamente um evento adverso (ex: elevação de HR em repouso nos 3 dias antes de episódios hipertensivos).
- Relatórios Semanais Personalizados: resumo narrativo do estado de saúde gerado por um LLM médico (GPT-4 Medical ou modelo fine-tuned) com base nos dados da semana.
- Sugestões Contextualizadas: recomendações de comportamento (hidratação, sono, exercício) calibradas ao perfil individual e ao momento atual.
- Dashboard Clínico para Profissionais: visualização consolidada do histórico e predições para o médico responsável, com indicadores de confiança do modelo.

4. Melhoria da Coleta de Informações via API

Além do sistema de IA adaptativa, a segunda grande melhoria proposta para o CarePlus Predict é o amadurecimento e a ampliação da camada de integração via APIs. A fase atual utiliza apenas simulações e a Samsung Health Data SDK; a proposta é construir um ecossistema de integração robusto, padronizado e resiliente.

4.1 Arquitetura de Integração Expandida

4.1.1 Samsung Health Data SDK — Implementação Avançada

A integração com Samsung Health evoluirá da leitura básica de dados para uma implementação completa:

- Streaming em tempo real via Samsung Health SDK 6.0+: coleta contínua em background com granularidade de 1 segundo para dados cardíacos.
- Acesso a dados avançados: Body Composition (% gordura, massa muscular via bioimpedância), Stress Index (índice de estresse calculado pelo próprio sensor Samsung), Blood Oxygen Saturation (SpO2) contínuo.
- Sincronização inteligente: estratégia de batching para dados históricos e streaming para dados críticos em tempo real, otimizando bateria e largura de banda.
- Tratamento de gaps: algoritmo de interpolação para preencher períodos sem dados (ex: quando o usuário remove o wearable) com marcação explícita de incerteza no modelo.

4.1.2 Novas APIs a Integrar (A ANALISAR)

O ecossistema de APIs do CarePlus Predict será expandido com as seguintes integrações:

API / Sistema	Dados Acessados	Protocolo	Frequência	Prioridade
RNDS (Rede Nacional de Dados de Saúde)	Sumário de alta, vacinação, resultados SADT	FHIR R4	Por evento	Alta
Pilula Dourada / Conexa Saúde	Histórico de consultas, prescrições	REST + OAuth2	Semanal	Alta
DASA / Fleury Labs API	Resultados de exames laboratoriais	HL7 FHIR	Por resultado	Alta
Google Fit / Apple HealthKit	Dados de usuários iOS/Android não Samsung	REST OAuth2	Diária	Média
OpenAQ / IQAir API	Qualidade do ar por geolocalização	REST	Horária	Baixa

Receita Federal CPF API	Validação de identidade do paciente	REST	Cadastro	Alta

4.1.3 Padrão FHIR para Interoperabilidade

Todas as integrações com sistemas de saúde adotarão o padrão HL7 FHIR R4 (Fast Healthcare Interoperability Resources), garantindo interoperabilidade com sistemas nacionais e internacionais:

- Resources utilizados: Patient, Observation, DiagnosticReport, MedicationRequest, Condition, Encounter, AllergyIntolerance.
- SMART on FHIR: autenticação padronizada para aplicações de saúde, garantindo acesso seguro e com escopo definido.
- CDS Hooks: integração com sistemas de suporte à decisão clínica para alertas em tempo de consulta.

4.2 Camada de API Gateway (A ANALISAR)

Para gerenciar todas as integrações de forma centralizada, o sistema implementará um API Gateway dedicado:

- Rate Limiting e Throttling: controle de requisições para evitar bloqueios por APIs externas.
- Circuit Breaker Pattern: quando uma API externa fica indisponível, o sistema degrada graciosamente sem impactar o usuário.
- Cache Inteligente: dados que mudam com baixa frequência (histórico clínico, exames antigos) são cacheados com TTL configurável para reduzir latência e custos de API.
- Retry Exponencial: tentativas automáticas com backoff exponencial para falhas temporárias de rede.
- Webhook Support: suporte a notificações push de sistemas externos (ex: resultado de exame disponível) sem polling contínuo.

4.3 Pipeline de Dados em Tempo Real (A ANALISAR)

A arquitetura de dados em tempo real será implementada com as seguintes tecnologias:

- Apache Kafka: broker de mensagens para ingestão de streams de dados do wearable com alta throughput e baixa latência.
- Apache Flink / Spark Streaming: processamento de eventos em tempo real para cálculo de features e disparo de alertas imediatos.
- TimescaleDB: banco de dados relacional otimizado para séries temporais (extensão do PostgreSQL), substituindo o PostgreSQL puro para dados biométricos.
- Redis: cache em memória para features calculadas em tempo real, evitando reprocessamento.

5. Segurança, Privacidade e Conformidade

Dados de saúde são considerados dados sensíveis pela LGPD e exigem padrões elevados de proteção. O CarePlus Predict adota uma abordagem Privacy-by-Design em todas as camadas do sistema.

5.1 Princípios de Segurança

- Criptografia End-to-End (E2E): todos os dados em trânsito são protegidos por TLS 1.3. Dados biométricos em repouso são criptografados com AES-256.
- Consentimento Explícito e Granular: o usuário controla exatamente quais dados são coletados, por quanto tempo e com quem são compartilhados. Consentimento pode ser revogado a qualquer momento.
- Federated Learning para Privacidade: o modelo de IA é treinado no dispositivo do usuário; apenas gradientes anonimizados trafegam para o servidor.
- Anonimização e Pseudonimização: dados utilizados no treinamento do modelo global são anonimizados e não podem ser revertidos ao paciente original.
- Zero Trust Architecture: nenhuma requisição é confiável por padrão; autenticação e autorização são verificadas em cada camada.

5.2 Conformidade Regulatória

Regulamento / Certificação	Status e Requisitos
LGPD (Lei 13.709/2018)	Conformidade total: DPO nomeado, RIPD elaborado, mecanismos de exercício de direitos implementados.
ANVISA — Software como Dispositivo Médico (SaMD)	Classificação como SaMD Classe II. Processo de certificação RDC 657/2022 em andamento.
CFM — Telemedicina	Adequação à Resolução CFM 2.314/2022 para laudos e consultas mediadas por tecnologia.
ISO 27001	Gestão de segurança da informação — roadmap para certificação em 12 meses.
HL7 FHIR R4	Interoperabilidade com sistemas de saúde nacionais e internacionais.
RNDS (Portaria 1.434/2020)	Integração com a Rede Nacional de Dados de Saúde do Ministério da Saúde.

5.3 Logs de Auditoria e Rastreabilidade

- Audit Trail completo: todas as operações de leitura, escrita e compartilhamento de dados de saúde são registradas em log imutável com timestamp e identificação do ator.
- Explicabilidade do Modelo (XAI): cada predição gerada pela IA é acompanhada de uma explicação em linguagem natural das features que mais influenciaram o resultado (via SHAP values).
- Retenção de Dados Configurável: políticas de retenção definidas por categoria de dado, com exclusão automática ao término do período.

6. Proposta de Valor e Diferenciais Competitivos

6.1 Para Pacientes

- Visão Unificada da Saúde: todos os dados clínicos e biométricos em um único lugar, acessível e compreensível.
- Alertas Preventivos Personalizados: notificações contextualizadas ao histórico individual, não alertas genéricos.
- Controle Total dos Dados: o paciente decide o que compartilha, com quem e por quanto tempo.
- Acompanhamento Contínuo: monitoramento 24/7 que não depende de consultas presenciais.

6.2 Para Profissionais de Saúde

- Dados Consolidados: visão completa do paciente sem necessidade de reunir informações de múltiplos sistemas.
- Insights Preventivos: alertas e tendências identificadas pela IA antes que se tornem emergências clínicas.
- Melhor Tomada de Decisão: suporte à decisão clínica baseado em evidências e no histórico específico do paciente.
- Comunicação Eficiente: canal direto e seguro com pacientes para orientações e acompanhamento pós-consulta.

6.3 Diferenciais Competitivos

Diferencial	Descrição
Foco Preditivo com IA Adaptativa	A plataforma não apenas monitora — ela aprende e se personaliza continuamente, antecipando riscos específicos de cada usuário.
Privacidade Nativa (Privacy-by-Design)	Proteção de dados incorporada ao design desde o início, com Federated Learning garantindo que dados brutos nunca deixem o dispositivo.
Interoperabilidade Total	Compatível com FHIR R4 e RNDS, comunicando-se com qualquer sistema de saúde nacional.
Mobile-First com Wearable Nativo	Experiência projetada primeiro para dispositivos móveis, com integração nativa ao ecossistema Samsung Health.

Explicabilidade Clínica (XAI)	Cada predição é acompanhada de justificativa compreensível para médicos e pacientes, diferente de modelos 'caixa-preta'.

7. Metas de Sucesso e Métricas

7.1 Métricas Técnicas

Métrica	Meta
APIs integradas e funcionais	3+ APIs na fase 2; 8+ APIs na fase 3
Precisão preditiva (modelo cardiovascular)	>= 92% (F1-Score)
Latência de resposta da API	< 2 segundos para 95% das requisições
Uptime da plataforma	>= 99,5% mensais
Cobertura de testes automatizados	>= 80% do código de produção
Tempo de atualização do modelo pessoal	Ciclos diários de 24 horas
Tamanho máximo do modelo no dispositivo	< 50MB para viabilidade mobile

7.2 Impacto Esperado

- Detecção precoce de eventos adversos cardiovasculares com janela de 48 a 72 horas de antecedência.
- Redução de custos de saúde via prevenção: estimativa de 20-30% de redução em internações evitáveis para usuários ativos.
- Aumento da adesão ao tratamento: monitoramento contínuo e feedback personalizado aumentam compliance medicamentoso.
- Empoderamento do paciente: maior compreensão do próprio estado de saúde e participação ativa nas decisões clínicas.

7.3 Roadmap de Desenvolvimento

Fase	Período	Entregas Principais	Status	Prioridade
Fase 1 — MVP	Concluída	App móvel, UI, simulações, arquitetura	Concluído	—
Fase 2 — Integração	Março - Maio	APIs reais, modelos preditivos v1, LGPD	Em andamento	Crítica
Fase 3 — IA Adaptativa	Maio - Julho	Federated Learning, fine-tuning pessoal	Planejado	Alta

Fase 4 — Escala	Julho - Agosto	ANVISA, FHIR completo, novos wearables	Planejado	Alta
Fase 5 — Expansão	Agosto - NEXT	B2B para hospitais, internacionalização	Conceito	Média

8. Stack Tecnológica Proposta (Atualizada)

8.1 Front-End e Mobile

- React Native 0.73+: framework unificado para Android e Web.
- Expo SDK: ferramentas de desenvolvimento e distribuição aceleradas.
- React Query / TanStack Query: gerenciamento de estado assíncrono e cache de dados do servidor.
- Victory Native / Recharts: visualizações de dados biométricos e dashboards clínicos.

8.2 Back-End

- Node.js com Fastify: API RESTful de alta performance com suporte a WebSockets para streaming.
- Python (FastAPI): microsserviço dedicado aos modelos de ML, expostos via API REST.
- Apache Kafka: ingestão de streams de dados do wearable.
- Redis: cache de sessão, rate limiting e pub/sub para alertas em tempo real.

8.3 Banco de Dados

- PostgreSQL 16: dados relacionais (usuários, consentimentos, configurações).
- TimescaleDB: extensão do PostgreSQL para séries temporais biométricas — queries de janela temporal otimizadas.
- MongoDB: armazenamento de documentos FHIR e dados semi-estruturados de prontuários.
- MinIO (S3-compatible): armazenamento de artefatos de modelo e dados brutos de wearable.

8.4 Machine Learning e IA

- Python: linguagem principal para desenvolvimento e treinamento de modelos.
- PyTorch / TensorFlow: frameworks de deep learning para modelos LSTM, Transformer e CNN.
- Scikit-learn / XGBoost: modelos de gradient boosting e ensemble para risco cardiovascular.
- SHAP (SHapley Additive exPlanations): geração de explicações para predições do modelo (XAI).
- Flower (flwr): framework de Federated Learning para treinamento distribuído e privado.
- MLflow: rastreamento de experimentos, versionamento de modelos e registro de métricas.
- ONNX Runtime: conversão e otimização de modelos para execução on-device (mobile).

- TensorFlow Lite / PyTorch Mobile: execução de modelos diretamente no dispositivo Android.

9. Fluxo do Sistema de IA Adaptativa — Passo a Passo

O ciclo de vida completo do sistema de IA adaptativa pode ser descrito em seis etapas sequenciais:

1. COLETA: O wearable Samsung captura dados biométricos continuamente (HR, HRV, SpO2, acelerômetro) e os sincroniza com o app via Samsung Health SDK a cada 1 segundo para dados críticos e a cada 5 minutos para dados agregados.
2. PRÉ-PROCESSAMENTO LOCAL: O app realiza limpeza básica dos dados no dispositivo (remoção de artefatos de movimento, valores fisiologicamente impossíveis) antes de enviar ao servidor, reduzindo volume e protegendo privacidade.
3. FEATURE ENGINEERING: O microsserviço Python calcula features em múltiplas janelas temporais (1h, 6h, 24h, 7d, 30d) e correlaciona com dados de APIs externas (prontuário, exames, qualidade do ar).
4. INFERÊNCIA DO MODELO: O modelo personalizado do usuário (ou o modelo global na ausência de dados suficientes) gera predições de risco em múltiplas dimensões, com scores de confiança e explicações via SHAP values.
5. ATUALIZAÇÃO DO MODELO: Em ciclos de 24 horas, novos dados são utilizados para atualizar incrementalmente o modelo pessoal do usuário via fine-tuning local com Federated Learning. Apenas gradientes são enviados ao servidor para agregação no modelo global.
6. ALERTAS E INSIGHTS: Predições que excedem thresholds configurados (personalizados por usuário e por tipo de condição) disparam notificações push para o paciente e, quando relevante, para o profissional de saúde vinculado.

10. Conclusão

O CarePlus Predict representa uma evolução significativa no paradigma de cuidados de saúde digitais no Brasil. Ao combinar a conveniência de uma plataforma mobile-first com o poder de uma IA que aprende e se adapta ao perfil individual de cada paciente, a plataforma endereça lacunas críticas do sistema de saúde atual.

As melhorias propostas nesta documentação — o sistema de IA Adaptativa inspirado no modelo NotebookLM e a expansão da coleta via APIs padronizadas (FHIR R4, RNDS, Samsung Health avançado) — elevam o CarePlus Predict de um aplicativo de monitoramento para uma plataforma de saúde preditiva genuinamente personalizada.

A adoção de práticas como Federated Learning, Privacy-by-Design, Explainable AI e conformidade regulatória total (LGPD, ANVISA, CFM) posiciona o projeto como uma referência em saúde digital responsável, preparado tanto para o mercado consumer quanto para adoção por operadoras de saúde e hospitais.

Com as fases de desenvolvimento planejadas, o CarePlus Predict tem o potencial de se tornar a plataforma de referência em prevenção de saúde personalizada no mercado brasileiro, contribuindo diretamente para a redução de custos no sistema de saúde e, fundamentalmente, para a melhoria da qualidade de vida de seus usuários.

FIAP — Faculdade de Informática e Administração Paulista
Projeto Next Gen — 1CCPS | Scrum Master: Allan Roberto | 2025